

查看此出版物的讨论、统计数据和作者简介at : <https://www.researchgate.net/publication/389129586>

改进大型多模态模型的微调，用于仇恨模因检测

预 印 本 · 2025 年 2 月 DOI :
10.48550/arXiv.2502.13061

引用0

阅 读
量44

5位作者，包括：



梅景彪
剑桥大学8篇出版物57次引证

查看个人资料

改进大型多模态模型的微调，用于仇恨模因检测

景彪梅、陈景红、杨光宇、林伟哲、比尔·伯恩

工程部

英国剑桥大学

英国剑桥，CB2 1PZ

{jm2245, jc2124, gy266, wl356, wjb31}@cam.ac.uk

摘

仇恨表情包已成为互联网上的重大隐患，亟需建立强大的自动化检测系统。尽管大型多模态模型在各类任务中展现出强大的泛化能力，但由于表情包内容与新兴社会趋势和突发新闻紧密相关且具有动态特性，导致其在仇恨表情包检测方面表现欠佳。最新研究进一步揭示了传统监督微调方法在此类场景下对大型多模态模型的局限性。为应对这些挑战，我们提出基于大型多模态模型检索的对比学习框架（LMMRGCL），这是一种创新的两阶段微调机制，旨在同时提升领域内准确性和跨领域泛化能力。在六个主流表情包分类数据集上的实验结果表明，LMM-RGCL取得了业界领先的表现，其性能超越了VPDPALI-X-55B等基于智能体的系统。此外，我们的方法在低资源环境下有效地推广到域外模因，超越了GPT-4o等模型。

本文包含演示内容，可能会让一些读者感到不安。

1 介

社交媒体的兴起导致仇恨内容激增，其中以表情包形式呈现的尤为突出。由于海量内容的存在以及人工审核员面临的心理风险，人工检测已难以实施。因此，仇恨表情包检测系统引发了学界广泛关注（基拉等人，2021；刘等人，2022；普拉卡什等人，2023；沙阿等人，2024）。

以往研究主要聚焦于监督学习场景，通过领域内训练数据对神经网络进行微调（普拉曼尼克等人，2021b；库马尔与南达库马尔，2022；布尔比等人，2023；林等人，2024）。然而现实世界中却出现了表情包等挑战。

这些系统会随着社会趋势和突发新闻持续演变，导致领域外泛化能力不足，常常无法识别新型仇恨言论模式（曹等人，2024）。考虑到每日内容生成速度和标注需求，频繁重新训练已变得不切实际。这些挑战突显了对可推广检测方法的需求，该方法在域内示例上表现良好，同时在低资源、域外场景中保持稳健性（Huang et al., 2024）。

尽管大型语言模型（LLMs）在各类任务中展现出强大的泛化能力（OpenAI, 2023），但最新研究表明，基础版大型多模态模型（LMMs）在检测仇恨表情包时表现欠佳，无论是领域内还是跨领域（梅等人，2024；黄等人，2024；何等人，2024；曹等人，2024）。值得注意的是，梅等人（2024）发现微调后的CLIP（Radford等人，2021）表现优于监督微调（SFT）的LMMs模型，如LLAVA-13B（刘等人，2023b）和Flamingo-80B（阿拉拉克等人，2022），这暴露出标准SFT方法在LMMs上的局限性。此外，研究还揭示了LMMs较差的跨领域泛化能力：例如，基于HatefulMememes数据集（基拉等人，2021）微调的LLaVA模型（专注于种族主义、性别歧视和宗教仇恨言论）无法将泛化能力迁移到针对新冠相关政治表情包的HarMeme（普拉曼尼克等人，2021a）。此外，黄等人...（2024）观察到，在上下文学习框架中，针对LMMs的仇恨模因检测仍然具有挑战性，这表明需要创新方法来更好地利用少量模因示例。

为解决这些挑战，我们提出大型多模态模型检索引导的对比学习（LMM-RGCL），一个两阶段微调框架，旨在提高域内和域外的仇恨表情包

检测方法。第一阶段联合多模态微调通过将语言建模损失与分类器的交叉熵损失相结合，快速调整LMM以适应仇恨表情包检测任务。第二阶段RGCL微调则通过学习区分检索到的正负样本，通过对语义相似的表情包对进行表征对齐，同时提升分类和检索能力。经过LMM-RGCL微调后，所学的嵌入空间支持基于检索的KNN多数投票机制，显著提升了对未见过样本的分类性能。我们证明该方法比脱离上下文的学习方式能更高效地利用少量表情包样本。LMM-RGCL使Qwen2VL-7B (王等人, 2024)在六个主流表情包分类数据集上取得顶尖表现，超越了VPD-PALI-X 55B (胡等人, 2024)等大型基于智能体的系统。此外，我们发现LMM-RGCL微调模型在未见过的表情包数据集上展现出比标准SFT显著更强的泛化能力。在资源有限的场景下，采用检索型KNN分类器的Qwen2VL-7B模型表现优异，其性能超越了GPT-4o (OpenAI, 2024a)和基于LLaVA-34B的LOREHM (Liu等人, 2023a)。我们的主要贡献包括：

1. 我们提出了一种创新的两阶段微调框架LMM-RGCL，该框架将联合多模态微调与RGCL微调阶段相结合。这种设计能同时提升分类和检索能力，有效实现对仇恨表情包检测的精准识别。
2. 我们证明，LMM-RGCL在六个广泛使用的模因分类数据集上实现了最先进的性能，优于依赖标准监督微调的更大的基于代理的系统。
3. 我们证明LMM-RGCL能显著提升模型对未见过的网络梗数据集的泛化能力，为领域内和领域外的仇恨梗检测提供了全面解决方案。据我们所知，这是首个在两种场景中均取得业界领先成果的系统。

2 相关工作

2.1 仇恨模因检测

目前大多数针对仇恨模因检测的方法都采用监督学习。早期系统 (朱,

2020年; 穆尼霍夫, 2020年) 微调的基于目标检测的视觉-语言模型，例如OSCAR (李等人, 2020年) 和 UNITER (陈等人, 2020)，这些方法采用了基于Faster R-CNN (Ren等人, 2015) 的目标检测器 (Anderson等人, 2018; Zhang等人, 2021)。

近年来，研究领域开始转向CLIP模型 (Radford等人, 2021)，因其端到端的简洁性和更强的多模态对齐能力。多项研究基于CLIP模型，通过不同模态融合机制对其进行了微调 (Pramanick等人, 2021b; Kumar与Nandakumar, 2022; Shah等人, 2024)。另有研究将描述性模型整合到CLIP特征融合网络中以进一步提升性能 (Burbic等人, 2023; Cao等人, 2023; Ji等人, 2024)。此外，对比学习技术也被用于解决模因分类中的干扰因素 (Lippe等人, 2020; Mei等人, 2024)。

虽然Flamingo (Alayrac等人, 2022) 等大型模型在通过自监督框架检测仇恨梗方面展现出潜力，但相较于基于CLIP的方法，针对大型模型的微调策略仍缺乏深入探索。事实上，Mei等人 (2024) 的研究表明，经过微调的CLIP模型性能甚至能超越规模更大的大型模型，这凸显了开发专门微调方法的必要性。在本工作中，我们提出了一种新的微调方法来提高LMMs在仇恨模因检测中的有效性。

2.2 低资源仇恨梗检测

低资源仇恨梗检测虽在需要跨领域泛化的实际应用中日益重要，但相关研究却相对匮乏。在此场景下，初始训练模型被部署到新领域时无需梯度更新，仅依赖示范样本进行推理 (Huang等人, 2024)。Hee等人 (2024) 通过基于文本相似性的少量样本帮助低资源模型实现跨领域泛化。类似地，Hu等人 (2024) 和Huang等人 (2024) 探索了基于代理的少量学习系统在跨领域场景中的应用。然而Huang等人 (2024) 发现，与其它任务相比，上下文无关学习在梗图分类中的效果较弱，这凸显了需要更有效的示范样本利用策略。相比之下，我们采用检索型多数投票方案对未知梗图进行分类，发现该方法比传统方法能更高效地利用示范样本。




图1：LMM-RGCL架构示意图。我们将LMM分解为两个组件：LMM骨干网络和语言模型头（LMH）。对于每个训练样本 i ，将最后一个隐藏状态 h_i 输入LMH以获得语言模型损失函数 $\mathcal{L}_i^{LM}$ 。同时，该隐藏状态 h_i 被输入可训练的多层感知机（MLP），生成用于检索查询的嵌入向量 g_i ，以及作为逻辑回归分类器（LRC）的特征来计算交叉熵损失函数 $\mathcal{L}_i^{LR}$ 。在训练过程中，从编码后的表情包数据库 G 中获取伪黄金样本和困难负样本，用于计算对比损失函数 $\mathcal{L}_i^{RGCLL}$ 。推理阶段采用相同流程检索 K 个最近邻样本进行基于检索的KNN分类（RKC），最终预测推理样本 t 的标签 y_t^{RKC} 。

在情境中学习。

3 LMM-RGCL方法

3.1 预备会议

问题陈述仇恨模因数据集是 defined as $\{(I_i, T_i, y_i)\}_{i=1}^N$, where $I_i \in \mathbb{R}^{H \times W}$ 是模因图像部分的像素值； T_i 是叠加在模因上的文字说明； $y_i \in \{0, 1\}$ 是标签，其中0表示无害，1表示恶意。大型多模态模型在使用LMM进行仇恨表情包检测的前期研究中，部分学者通过文本生成方法来解决该问题，即以表情包 (I_i, T_i) 作为输入，预测单一标记标签 y 。LMH $\in \{“良性”, “仇恨”\}$ （林等人，2024；黄等人，2024）。我们将LMM的最终线性层称为LM头（LMH），该模块通过softmax函数将隐藏表示映射为词汇表的概率分布。在表情包分类任务中，LMH会解码最后一个标记的隐藏状态并生成输出标签。这与基于CLIP的方法形成对比——后者通过编码器CLS标记训练逻辑回归分类器（LRC）（库马尔和南达库马尔，2022；梅等人，2024）。

3.2 LMM-RGCL框架

架构如图1所示，LMM RGCL将LMM与两个附加组件集成在一起。

训练组件包括：多层感知机（MLP），可将LMM的最终隐藏状态 h_i 映射为用于分类和检索的嵌入向量 g_i ；以及基于 g_i 运行的LRC。图1展示了该架构如何支持多种微调 and 推理模式。

检索在培训期间，基于FAISS的（约翰逊等人。在对比学习中，2021年提出的最近邻搜索方法从编码模因数据库 G 中检索伪黄金正例（Mei等人，2024）和困难负样本（Schroff等人，2015）。推理阶段采用FAISS算法为基于检索的KNN分类器（RKC）检索邻近样本。

推理模式示意图1展示了三种不同的分类器：LMH、LRC和RKC。对于预训练的LMM和SFT LMM，我们沿用前人研究（第3.1节）中的LMH结果进行报告。对于LMM-RGCL模型，除非特别说明，否则均采用LRC结果。第4.5节将对这三种推理模式进行详细对比分析。

3.3 阶段1：联合多模态微调

在第一阶段，我们通过低秩自适应技术（Hu等人，2022）对低秩矩阵模型（LMM）进行微调。该技术在冻结原有权重的同时，将可训练的低秩矩阵应用于模型。多层感知机（MLP）和低秩自适应器（LRC）同步更新，最终通过优化联合损失函数实现整体优化。

对于每个训练示例 i :

$$\mathcal{L}_{\text{阶段1}i} = \mathcal{L}_{\text{LM}i} + \mathcal{L}_{\text{LR}i}, (1)$$

其中 $\mathcal{L}_{\text{LM}i}$ 表示序列到流 (SFT) 中使用的语言建模目标函数。在模因分类的语境下, 该模型经过训练以预测单个目标标记 $s(y_i)$, 其表达式为:

$$s(y_i) = \begin{cases} \text{"benign"} & \text{if } y_i = 0 \\ \text{"hateful"} & \text{if } y_i = 1 \end{cases}. (2)$$

$\mathcal{L}_{\text{LM}i}$ 的计算方式是: 在输入图像和文本的条件下, 生成正确目标标记的负对数似然。

$$\mathcal{L}_{\text{LM}i} = -\log p(y^{\text{LM}Hi} = s(y_i) | i, T_i) (3)$$

$\mathcal{L}_{\text{LR}i}$ 是应用于 LRC 预测 $y^{\text{LRC}i}$ 的二元交叉熵损失:

$$\mathcal{L}_{\text{LR}i} = -y_i \log y^{\text{LRC}i} - (1 - y_i) \log (1 - y^{\text{LRC}i}) (4)$$

联合优化语言建模损失 $\mathcal{L}_{\text{LM}i}$ 和交叉熵损失 $\mathcal{L}_{\text{LR}i}$, 使 LMM 能够快速适应仇恨模因检测任务。

3.4 阶段2: RGCL微调

在第二阶段, LMM 被冻结; 仅对 MLP 和 LRC 进行微调以优化检索对齐的表征。第二阶段联合优化:

$$\mathcal{L}_{\text{阶段2}i} = \mathcal{L}_{\text{RGCL}Li} + \mathcal{L}_{\text{LR}i}, (5)$$

其中, $\mathcal{L}_{\text{LR}i}$ 在方程4中定义, $\mathcal{L}_{\text{RGCL}Li}$ 是检索引导的对比学习损失。

为计算 $\mathcal{L}_{\text{RGCL}Li}$, 我们从训练集中获取伪黄金正例和困难负例。具体而言, 对于给定样本 i 及其嵌入向量 g_i , 我们采用 FAISS (Johnson等人提出的算法) 进行匹配。 (2021) 在训练集中执行最近邻搜索, 将 g_i 与每个其他目标嵌入 $g_j \in G$ 进行比对。编码后的模因数据库 G 在微调过程中每100步更新一次。

伪黄金正例是指与 g_i 具有高相似度得分的标签样本, 而硬负例则是指与 g_i 具有高相似度得分的反标签样本。我们将伪黄金正例和硬负例的嵌入向量分别记为 g^+ 和 g^- 。随后计算 $\mathcal{L}_{\text{RGCL}Li}$ 公式如下:

$$\begin{aligned} \mathcal{L}_i^{\text{RGCLL}} &= L(g_i, g_i^+, g_i^-) \\ &= -\log \frac{e^{\text{sim}(g_i, g_i^+)}}{e^{\text{sim}(g_i, g_i^+)} + e^{\text{sim}(g_i, g_i^-)}}, (6) \end{aligned}$$

其中 $\text{sim}(\cdot, \cdot)$ 表示余弦相似度函数。第二阶段的微调通过显式对语义相似的模因对表示进行对齐, 从而提升语言模型对未见数据集中分布偏移的泛化能力。

3.5 基于检索的KNN分类

除了 LMH 和 LRC 之外, RKC 专门用于跨领域模因分类。对于测试模因 t , 我们从模因数据库 G 中检索嵌入空间内的 K 个相似模因。通过相似度加权多数投票获得预测结果:

$$\hat{y}_t^{\text{RKC}} = \sigma\left(\sum_{k=1}^K \bar{y}_k \cdot \text{sim}(g_k, g_t)\right), (7)$$

其中 $\sigma(\cdot)$ 是 S 型函数, 且

$$\bar{y}_k := \begin{cases} 1 & \text{if } y_k = 1 \\ -1 & \text{if } y_k = 0 \end{cases}. (8)$$

此外, 为了在未集成多层感知机的预训练或自监督框架学习模型 (SFT LMMs) 上实现 RKC 算法, 我们采用最近邻搜索时使用最后一个隐藏状态 h_i 。具体结果详见附录 D。

4 实

我们通过六个主流网络梗分类数据集评估系统性能: 仇恨梗 (基拉等人, 2021)、哈密梗 (普拉曼尼克等人, 2021a)、MAMI (费尔西尼等人, 2022)、Harm P (普拉曼尼克等人, 2021b)、MultiOFF (苏里万希等人, 2020) 以及 PrideMM (沙阿等人, 2024)。这些数据集在不同社会政治背景下对有害内容的定义各不相同 (包括仇恨、冒犯或针对性骚扰等类型)。具体描述与统计数据详见附录 A。

针对 Hateful Memes、HarMeme 和 MAMI 模型, 我们采用与先前研究一致的评估指标——受试者工作特征曲线下面积 (AUC) 和准确率 (Acc), 具体参考文献包括 Kumar 与 Nandakumar (2022)、Cao 等人 (2023)、Mei 等人 (2024) 及 Cao 等人 (2024)。对于 Harm-P、MultiOFF 和 PrideMM 模型, 我们采用与文献一致的评估标准, 准确率和 F1 分数分别参考 Pramanick 等人 (2021b)、Mei 等人 (2024)、Shah 等人 (2024) 及 Lin 等人 (2024)。附录 B 详细列出了模型实现细节、超参数设置及统计显著性检验流程。

模型	仇恨表情包		哈米		妈妈		哈姆-P		多边形关闭		骄傲MM	
	AUC	Acc.	AUC	Acc.	AUC	Acc.	Acc.	F1	Acc.	F1	Acc.	F1
最好的 先前结果	VPD-55B		问题		职业帽		解释HM		RGCL		MemeCLIP	
	89.2	80.8	92.8	81.6	83.8	73.6	<u>90.7</u>	<u>90.7</u>	67.1	58.1	76.1	75.1
基于CLIP的监督微调分类器												
1 CLIP MO-	79.8	72.0	82.6	76.8	77.7	68.4	80.6	80.3	62.4	48.1	72.4	72.3
2 MENTA 仇 恨	69.2	61.3	86.3	80.5	81.7	72.1	89.8	88.3	-	-	72.2	71.8
3 剪辑器RGCL	85.5	76.1	89.7	84.8	87.2	74.8	87.6	86.9	62.4	54.8	75.5	74.1
4	87.0	78.8	91.8	87.0	89.4	78.4	89.9	89.5	67.1	58.1	76.3	76.5
大型多模态模型												
LLaVA-1.5-7B 5 w/ 零射程	63.7	57.6	71.4	48.6	67.6	58.3	61.6	46.4	59.6	51.7	63.4	65.6
6 w/ few-shot	63.4	57.2	73.4	59.6	68.1	62.7	53.5	52.2	38.9	56.0	62.1	64.0
7 w/ SFT	85.2	78.7	91.4	79.1	86.0	73.9	82.8	82.8	67.8	57.8	73.2	76.0
8与LMM-RGCL的p	<u>89.7</u>	<u>80.9</u>	93.5	88.2	91.2	<u>79.7</u>	89.6	89.3	<u>70.9</u>	<u>63.6</u>	78.1	78.7
值Qwen2VL-2B	$9.8e^{-3}$	$3.5e^{-3}$	$1.2e^{-2}$	$8.5e^{-3}$	$4.4e^{-3}$	$6.2e^{-3}$	$2.5e^{-3}$	$1.6e^{-3}$	$6.1e^{-3}$	$4.6e^{-3}$	$5.6e^{-3}$	$8.9e^{-3}$
9 w与零射程	64.8	54.2	61.1	56.7	67.2	51.0	53.9	21.8	63.1	36.3	57.8	53.3
10/很少使用	61.7	59.1	62.1	65.8	64.8	58.8	53.0	51.6	67.1	44.9	55.4	54.3
11 w/ SFT	84.0	76.2	90.2	82.5	77.7	68.6	80.3	79.7	66.4	54.5	73.7	74.2
12 w/ LMM-RGCL	88.4	79.1	92.9	87.7	89.3	79.4	88.9	88.7	68.5	61.8	76.0	76.7
p值Qwen2VL-7B	$4.2e^{-3}$	$4.8e^{-3}$	$9.1e^{-3}$	$7.6e^{-3}$	$6.5e^{-4}$	$1.9e^{-4}$	$9.3e^{-4}$	$1.1e^{-3}$	$2.0e^{-2}$	$7.7e^{-3}$	$7.1e^{-3}$	$8.3e^{-3}$
13个零启动	71.9	63.2	64.8	64.1	76.2	58.5	55.5	22.9	63.4	35.9	65.3	62.9
14/w/few-shot	71.5	63.8	71.5	67.2	73.4	66.1	55.6	65.2	64.4	54.7	69.1	56.6
15 w/ SFT	86.3	78.6	91.8	85.9	82.6	72.4	85.9	86.3	67.8	55.5	75.1	74.9
16与LMM-RGCL的	91.1	82.1	<u>93.2</u>	<u>88.1</u>	<u>90.4</u>	79.9	91.6	91.1	71.1	64.8	78.1	<u>78.4</u>
p值	$8.7e^{-4}$	$2.4e^{-3}$	$3.5e^{-2}$	$1.6e^{-2}$	$2.5e^{-3}$	$2.6e^{-3}$	$6.3e^{-3}$	$8.6e^{-3}$	$1.3e^{-2}$	$5.9e^{-3}$	$9.2e^{-3}$	$7.2e^{-3}$

表1：在监督设置下与基线系统的比较。针对大型多模态模型，我们展示了预训练模型在零样本和少样本场景下的性能表现（采用四样本评估），并对比了SFT与LMM-RGCL的优劣。此外，针对每个LMM模型，我们提供了SFT与LMM-RGCL之间显著性检验的p值。所有p值均低于0.05。最佳性能以粗体标出，次优结果则用下划线标注。

4.1 在监督设置下将LMM-RGCL与基线系统进行比较

表1展示了监督微调设置下基线系统的性能表现。我们将LMM-RGCL与一系列强基线模型进行对比：包括各数据集的最佳先验模型¹、基于CLIP的监督微调分类器，以及大型多模态模型（LMMs）。所有模型均经过单独微调并针对每个数据集进行评估。

基于CLIP的分类器我们将微调后的CLIP（Radford等人，2021）模型与另外三种微调方法进行性能对比，这三种方法均基于CLIP系统：MOMENTA（Pramanick等人，2021b）、HateCLIPper（Kumar 和 Nandakumar，2022）以及RGCL（Mei等人，2024）。

大型多模态模型实验我们选取了来自两个模型家族的三个大型多模态模型进行测试：LLaVA-1.5-7B（刘等人，2023a）、Qwen2VL-2B 和 Qwen2VL-7B（王等人，2024）。我们将在以下场景下报告这些大型多模态模型的性能表现：零样本预训练模型、少量样本预训练模型以及...

¹根据近期论文（Nguyen和Ng，2024）的研究结果，部分数据集已更新为最新最佳结果。

在LMM-RGCL微调框架下，分别采用LMH进行射击提示、使用LMH的SFT LMM以及LRC进行分类。

最佳先验模型视觉程序蒸馏（VPD）（胡等人，2024）和ExplainHM（林等人，2024）是基于LLM代理的系统。其余前沿模型包括ISSUES（伯比等人，2023）、Pro-Cap（曹等人，2023）、RGCL（梅等人，2024）和MemeCLIP（沙阿等人，2024），这些模型均基于对CLIP视觉与语言模型的微调。相关方法的详细说明详见附录C。

观察结果1：经过微调的基于CLIP的分类器优于基线LMM。如表1所示，RGCL（#4）在基于CLIP的分类器中表现最佳，在多个数据集上比标准微调CLIP（#1）高出约10%。在6个数据集中有5个，RGCL的表现优于或与所有三种SFT LMM（#7、#11、#15）持平。

观察结果2：在语境中学习对模因分类的有效性有限。我们比较了预训练模型在零样本（#5、#9、#13）和少样本（#6、#10、#14）场景下的性能表现。

评估日期 模型		HatefulMemes		哈密		妈妈		哈姆-P		多边形关闭		PrideMM	
		AUC	Acc.	AUC	Acc.	AUC	Acc.	Acc.	F1	Acc.	F1	Acc.	F1
资源不足的系统													
1	GPT-4o Mod- HateLOREHM	-	65.0	-	67.2	-	62.9	52.4	5.6	63.1	15.4	58.0	25.8
2		64.5	58.0	73.4	69.5	67.4	61.0	-	-	-	-	-	-
3		-	<u>65.6</u>	-	73.7	-	<u>75.4</u>	-	-	-	-	-	-

在跨数据集设置下微调的系统													
微调设置		哈密		仇恨表情包									
4	RGCL LLaVA-1.5-7B	69.9	66.9	64.3	61.1	67.8	62.4	56.4	57.1	53.7	45.1	59.8	61.5
5	<i>SFT + 零射程</i>	63.8	59.4	61.9	48.5	69.1	61.1	55.2	28.7	62.8	32.5	58.1	53.3
6	<i>SFT + 少样本</i>	63.1	56.4	69.9	52.8	65.5	50.1	55.6	49.6	56.0	38.9	48.5	55.3
7	<i>LMM-RGCL + RKC</i> Qwen2VL-2B	74.2	65.2	89.5	81.9	80.0	74.5	67.3	67.8	62.4	51.7	68.8	67.7
8	<i>SFT + 零射程</i>	64.1	59.7	61.3	52.2	66.4	57.3	53.5	20.3	62.3	29.3	56.4	59.0
9	<i>SFT + 少样本</i>	61.3	53.8	57.4	65.0	73.8	66.0	56.9	55.5	53.7	42.4	55.4	60.9
10	<i>LMM-RGCL + RKC</i> Qwen2VL-7B	70.9	62.8	86.0	78.4	74.8	72.3	63.4	66.0	<u>63.4</u>	53.4	<u>69.0</u>	69.1
11	<i>SFT + 零射程</i>	71.1	64.1	63.0	55.2	71.1	61.9	54.7	21.5	63.1	29.7	64.5	63.6
12	<i>SFT + 少样本</i>	72.3	60.6	67.2	62.4	73.4	66.0	56.4	64.9	62.0	<u>53.7</u>	55.4	60.9
13	<i>LMM-RGCL + RKC</i>	77.1	69.3	88.8	<u>81.7</u>	81.4	75.6	64.5	66.4	63.8	55.6	69.3	69.3

表2：低资源环境下跨领域模因分类性能对比。针对在跨数据集场景下微调的系统，模型在HarMeme数据集上进行微调并在HatefulMemes数据集上评估。其余评估数据集的模型均在HatefulMemes数据集上微调。对于LMM模型，我们通过零样本学习和上下文学习对比SFT模型与使用RKC微调的LMM-RGCL模型。少量样本（4次）和RKC样本均从各评估数据集的训练集划分中抽取。

#2和#3取自原始论文。最佳性能用粗体突出显示；第二佳用下划线表示。

LMMs。我们的研究表明，与某些其他任务不同，在情境中学习对模因分类并无益处，这与先前的研究结果一致(Hee等人。(黄等人，2024)。HarMeme是唯一一个少样本系统持续优于零样本系统的数据集。在Harm-P和MultiOFF任务中，尽管零样本与少样本的准确率仍处于可比水平，但少样本实验在F1分数上取得了显著提升。这种改进源于系统在获得示范样本后，其精确度与召回率达到了更均衡的状态。

观察结果3：LMM-RGCL在6个数据集上优于所有强基线系统

针对六个数据集和三种LMM模型，使用LMM-RGCL进行微调后，其性能较SFT显著提升（表1：#7、#8；#11、#12；#15、#16）。通过统计学检验进一步验证了这一结论，所有p值均低于0.05。值得注意的是，如#16所示，在HatefulMemes数据集上，采用LMM-RGCL微调的Qwen2VL-7B模型表现优于VPD-PaLI-X-55B。此外，LMM-RGCL在HatefulMemes数据集上的AUC指标提升了超过4%，准确率提高了3%。这些改进充分证明了LMM-RGCL在优化LMM模型方面的有效性。

for meme classification over SFT.

4.2 在低资源设置下比较LMM-RGCL与基线系统

网络仇恨言论持续演变，随着网络上流传的模因分布与训练数据存在差异，这对现有系统构成了严峻挑战。为模拟真实场景中的部署限制，我们在低资源环境下对系统进行跨领域样本评估——该环境禁止梯度更新，仅允许使用示范样本（Huang等人，2024；Hee等人，2024；Cao等人，2024）。

我们采用与Mei等人（2024）相似的跨数据集评估方案：在HarMeme上微调的模型将在HatefulMemes上进行测试，而基于HatefulMemes训练的模型则会在其他所有数据集上进行评估。这种方案模拟了将训练好的模因分类系统部署到实际场景中评估热门模因的情况。为避免测试集污染，我们从每个目标评估数据集的训练集中抽取少量样本和RKC示例。

我们将经过RKC微调的LMM-RGCL模型与RKC进行对比，测试系统包括：采用零样本和少量样本提示的SFT LMMs——

包括 LMH 模型、GPT-4o (OpenAI, 2024a) 以及专用低资源系统 (LOREHM (黄等人, 2024)、Mod-hate (曹等人, 2024))。对于 GPT-4o, 由于无法获取标记概率来计算 AUC 分数。关于 Mod-hate 和 LOREHM, 我们直接采用原始论文中的实验结果进行报告。

观察结果1：在模因分类数据集上进行微调并不能帮助LMMs提高在其他模因分类数据集上的泛化能力

跨领域微调的LMM模型在零样本或少量样本提示任务中，相较于预训练LMM模型均未呈现持续性性能提升。Qwen2VL-7B 零样本模型（表2第11项）在HatefulMemes和PrideMM数据集上的表现与SFT模型（表1第13项）相当，但在其余四个数据集上则出现性能下降。

观察结果2：在上下文中的学习对SFT LMM仍然无效

如表2 #6、#9和#12所示，即使对不同仇恨表情包数据集领域进行微调后，少样本方法依然表现平平，与SFT零样本模型相比未见显著提升（表2 #5、#8、#11）。在第4.4节中，我们进一步对比了上下文学习所需的样本数量发现，增加样本量并不能有效提升性能。

观察结果3：使用RKC推理模式微调的LMMs优于基线方法

在相同的跨数据集微调设置下，使用RKC微调的LMM-RGCL模型在零样本和少样本场景中均优于基线SFT LMMs。值得注意的是，通过RKC训练Qwen2VL-7B时，LMM-RGCL在HarMeme数据集上的AUC指标比基线SFT少样本模型提升了21.6%，准确率提高了19.3%（表2#11-13）。第4.4节的消融实验通过调整RKC的前k值数量，进一步证明RKC比少样本上下文学习框架更有效地利用示范样本。此外，我们在附录D中对比了RKC对预训练LMMs和SFT LMMs的改进效果。

观察结果4：使用RKC推理训练的LMMs优于其他低资源方法

相较于GPT-4o，我们采用RKC微调的LMM-RGCL Qwen2VL-7B模型在HarMeme数据集上准确率提升14.5%，在PrideMM数据集上准确率提升11.3%。与其他使用类似开源LMM方法的低资源模型相比，我们的

经过RKC微调的LMM-RGCL模型在HatefulMemes数据集上的表现与LOREHM不相上下。值得注意的是，LOREHM采用了规模大得多的LLaVA-1模型。在基于代理的框架下，我们的方法在HarMeme数据集上准确率比LOREHM高出8.2%，这充分证明了该方法在低资源场景下的有效性。

4.3 两阶段微调的影响

我们评估了两阶段LMM-RGCL微调流程中各阶段的影响。如表3a和表3b所示，在监督学习和跨数据集场景下，无论省略哪个阶段都会导致性能下降。其中省略第一阶段造成的性能损失最为显著，这主要是因为大型多模态模型（LMM）的骨干网络在第二阶段保持冻结状态所致。

模式	HatefulMemes		哈米	
	AUC	Acc.	AUC	Acc.
LMM-RGCL 无	91.1	82.1	93.2	88.1
阶段1	84.4	74.2	90.1	85.6
无/第二阶段合并阶段	90.2	81.4	92.0	86.2
段	88.9	77.8	90.2	83.4

(a) 监督设置，详见表1中的详细设置

模式	仇恨表情包		哈米	
	AUC	Acc.	AUC	Acc.
LMM-RGCL	77.1	69.3	88.8	81.7
/无阶段1	72.0	62.1	84.9	78.1
/无阶段2	74.4	66.7	86.3	78.7
联合阶段	72.2	65.3	87.5	80.2

(b) 跨数据集设置，详见表2

表3：LMM-RGCL两阶段微调框架在Qwen2VL-7B上的消融研究，评估第一阶段联合多模态微调与第二阶段RGCL微调的影响。对于“联合阶段”，我们在单次训练过程中同步优化两个阶段的三个损失目标函数。

当省略第二阶段时，监督学习场景下的性能损失比跨数据集场景要轻。我们认为这是由于第二阶段采用了对比损失函数，该机制通过对语义相似的梗图对进行表征对齐，从而显式优化检索能力。这种表征对齐机制能有效提升模型在未见数据集中的分布漂移鲁棒性。

对于“组合阶段”，我们联合优化两个阶段的目标：

$$\mathcal{L}_{\text{组合式}} = \mathcal{L}^{\text{RGCLLi}} + \mathcal{L}^{\text{LRI}} + \mathcal{L}^{\text{LMI}}. \quad (9)$$

在监督学习环境下，该方法的性能表现欠佳：HatefulMemes数据集的AUC值下降2.2%，HarMeme数据集的AUC值下降3.0%。实验结果表明，两阶段微调策略能有效缓解第一阶段任务适应与第二阶段表征对齐之间的优化冲突。值得注意的是，由于LMM模型在此组合损失目标下仍保持可训练状态，相较于将LMM冻结在第二阶段的两阶段微调方案，更新编码模因数据库需要消耗更高计算成本。这种微调阶段的分离设计既保证了模型性能，又提升了训练效率。更多训练时间细节详见附录B。

针对每个阶段，我们通过在微调过程中逐一移除损失目标进行消融研究。结果表明，每一项对于最优性能都是至关重要的。详细结果详见附录E。

4.4 拍摄次数和邻居

我们消除了少量样本上下文学习中改变拍摄次数的影响，以及RKC中改变前K个最近邻数量的影响。

图2表明，对于语言模型而言，增加上下文示例的数量并不能始终如一地带来比零样本设置更好的性能提升，某些情况下甚至会导致性能下降。这些发现表明，单纯增加样本数量未必能提升性能，这与黄等人（2024）的研究结果一致。

图2显示，随着RKC的最近邻数量K增加，AUC和准确率的性能持续提升，并在K = 20左右趋于平稳。这种性能的持续改善表明，相较于标准的上下文无关学习框架，采用LMM-RGCL训练的RKC能更有效地利用示范样本。

4.5 比较不同的推理模式

表4对比了使用LMM-RGCL微调的Qwen2VL-7B模型在三种分类器上的表现。实验结果表明，在监督学习场景下，三种推理模式间的差异微乎其微。然而在跨数据集测试时，泛化性能却呈现出显著差异。值得注意的是，RKC模型在这两方面均展现出更优的性能表现。




图2：使用预训练LMM时增加上下文无关学习样本数量的效果，以及使用LMM-RGCL训练的RKC方法中增加前K个最近邻的影响

和LRC，强调了它在处理域外示例方面的优越性。

推理模式	HatefulMemes		哈米	
	AUC	Acc.	AUC	Acc.
玛格丽特夫人会堂	90.2	81.9	92.8	88.0
远程通讯	91.1	82.1	93.2	88.1
美国	90.8	81.8	93.2	88.0

(a) 监督设置，详见表1中的详细设置

推理模式	仇恨表情包		哈米	
	AUC	Acc.	AUC	Acc.
玛格丽特夫人会堂	70.2	64.3	64.5	60.3
远程通讯	59.5	55.4	57.9	52.2
美国	77.1	69.3	88.8	81.7

(b) 跨数据集设置，详见表2

表4：使用LMM-RGCL微调Qwen2VL-7B对比不同推理模式。RKC相比其他推理模式展现出更优异的跨领域泛化能力。

5 结

我们提出LMM-RGCL（两阶段微调框架），旨在提升LMM在仇恨表情包分类任务中的表现，有效解决了传统SFT方法的局限性。该框架不仅显著提升了领域内分类精度，还增强了跨领域泛化能力。通过六个主流表情包分类数据集的测试结果，LMM-RGCL展现出卓越的性能优势，充分验证了其有效性。

局限性

针对仇恨言论的定义存在多种表述方式，包括网络骚扰、网络攻击、网络欺凌及有害言论等。联合国《仇恨言论战略与行动计划》明确指出，相关定义可能引发争议并存在讨论空间（恩德里图，2020）。英国《网络伤害白皮书》同样强调，某些危害的具体界定可能存在不足（伍德豪斯，2022）。

我们承认，仇恨言论的定义具有主观性且因文化法律背景不同而存在差异。为此，我们在六个主流表情包分类数据集上验证方法，确保其在不同仇恨言论定义下的普适性。随着相关定义的持续发展，我们将研究同步推进，并计划在新数据集发布时及时纳入。通过错误分析发现，系统无法识别表情包中细微的视觉细节特征。

通过更强大的视觉编码器增强图像理解可以进一步提高性能，我们将其留作未来的工作。

伦理声明

可重复性。为保证可重复性，详细的实验设置、具体实现细节和超参数设置详见附录B。源代码将在论文发表后公开。

数据集使用说明。本研究采用的HatefulMemes、HarMeme、MAMI、HarmP、MultiOff和PrideMM等数据集，均经过专业整理用于反网络仇恨言论研究。我们严格遵守各数据集提供方制定的使用条款。

社会效益。像LMM-RGCL这样的仇恨模因检测系统，能自动识别网络上的恶意内容，对减少网络仇恨言论具有显著作用。通过遏制仇恨言论、营造更安全的数字环境并协助人工审核团队，这些系统对网络交流与信息安全产生深远影响。我们认为，在构建更安全、更具尊重精神的数字空间这一宏大目标中，这些技术带来的效益既重要又不可或缺。

预期用途。我们计划对模型发布实施严格的访问控制。该模型仅对同意我们使用条款的研究人员开放，该条款明确指出，系统专为检测和预防仇恨言论而设计。严禁将本模型用于任何推广、纵容或鼓励仇恨言论或有害内容的目的。

滥用风险。虽然我们的系统本身并非设计用于引发偏见，但在使用HatefulMemes等现有数据集进行训练时，可能会无意中将现有偏见传导至特定个人、群体或实体（Pramanick等人，2021b）。为降低因数据集引发的偏见导致的不公正审核风险，若部署该系统，必须在审核流程中加入人工监督机制。

部署考量。文化差异与主观话题会引发网络仇恨言论的调节偏差。某些看似温和的表述，在他人眼中可能极具冒犯性。我们的RKC推理模式通过检索跨领域通用的示例，无需重新训练即可创建多个检索集，精准适配不同文化背景下的敏感性需求。不过，在部署这类系统前，必须仔细评估数据集标注内容，特别是在处理文化差异和主观解读时。关键因素包括数据整理规范、标注者潜在偏见，以及仇恨言论本身具有情境依赖性的定义特征。这些考量对于确保系统能在不同文化背景下负责任且高效地部署至关重要。

环境影响模型的大型化训练不仅计算量巨大，还会因大量使用GPU/TPU芯片而加剧全球变暖。我们通过采用量化LoRA（低资源自适应学习）这一参数优化方法对LMM进行微调，有效解决了这个问题。该方案可在单个GPU上完成四小时以内完成训练，相比传统全量微调方式，既大幅缩短了训练周期又降低了计算成本。此外，由于我们的方法无需重新训练即可跨领域通用，进一步显著减少了计算资源消耗。

参考文献

让-巴蒂斯特·阿拉亚克、杰夫·多纳休、保琳·吕克、安托万·米耶克、伊恩·巴尔、亚娜·哈森、卡雷尔·伦茨、亚瑟·门施、凯瑟琳·米利坎、马尔科姆·雷诺兹、罗曼·林、伊丽莎·卢瑟福、塞尔坎·卡比、滕达·韩、龚志涛、西娜·萨曼古伊、玛丽安·蒙泰罗、雅各布·L·梅尼克、塞巴斯蒂安·博尔若、安迪·布洛克、艾达·内马扎德、萨汉德·沙里夫扎德、Mikołaj·比恩科夫斯基、里卡多·贝雷拉、奥里奥尔·维尼亚尔斯、安德鲁·齐瑟曼和卡伦·西蒙扬。2022年。火烈鸟：一种用于少样本学习的视觉语言模型。《神经信息处理系统进展》第35卷：23716–23736页。

彼得·安德森、何晓东、克里斯·布勒、达米安·特尼、马克·约翰逊、斯蒂芬·古尔德和张磊。2018年。自下而上与自上而下的图像注意力机制
图像标注与视觉问答。收录于2018年IEEE/CVF计算机视觉与模式识别会议论文集，第6077–6086页。

乔瓦尼·布尔比、阿尔贝托·巴尔德拉蒂、洛伦佐·阿尼奥卢奇、马可·贝尔蒂尼与阿尔贝托·德尔宾博。2023年。《将表情包映射为文字实现多模态仇恨表情包分类》。收录于2023年IEEE/CVF国际计算机视觉研讨会 (ICCVW) 论文集，第2824–2828页。

曹睿、何明山、阿德里尔·库克、钟文豪、李嘉伟与姜静。2023年。Pro-cap：基于冻结视觉语言模型的仇恨梗检测方法。收录于第31届ACM国际多媒体会议论文集 (MM '23)，第5244–5252页。美国计算机协会。

曹睿、李凯伟、钟文豪与姜静。2022年。《多模态仇恨表情包分类的提示机制研究》。收录于《2022自然语言处理实证方法会议论文集》第321–332页，阿拉伯联合酋长国阿布扎比。计算语言学协会。

曹睿、李凯伟、姜静。2024年。模块化网络在少样本仇恨梗检测中的应用。收录于《ACM网络会议2024论文集》(WWW '24)，第4575–4584页。美国计算机协会。

陈燕春、李林杰、余立成、艾哈迈德·埃尔·霍利、费萨尔·艾哈迈德、甘哲、程宇和刘晶晶。2020年。《UNITER：通用图像文本表示学习》，收录于《计算机科学讲义》第12375卷，第104–120页。施普林格国际出版集团，中国上海。

戴文亮、李军南、李东旭、孟华彤、赵俊奇、王伟生、李博阳、冯帕斯卡和何世勋。2023年。《指令微粒：通过指令调优实现通用视觉语言模型》(arXiv:2305.06500)。
ArXiv:2305.06500 [cs].

DeepSeek-AI. 2025. Deepseek-r1：通过强化学习(arXiv:2501.12948激励LLM的推理能力)。ArXiv:2501.12948 [cs].

蒂姆·德特默斯、阿蒂多罗·帕尼奥尼、阿里·霍尔茨曼与卢克·泽特勒莫耶。2023年。《Qlora：量化语言模型的高效微调》(arXiv:2305.14314)。
ArXiv:2305.14314 [cs].

伊丽莎贝塔·费尔西尼、弗朗切斯卡·加斯帕里尼、朱莉娅·里齐、奥罗拉·赛本内、贝尔塔·丘尔维、保罗·罗索、艾丽莎·李斯和杰弗里·索伦森。2022年。Semeval-2022任务5：多媒体自动性别歧视识别。收录于第16届国际语义评估研讨会 (SemEval-2022) 论文集，美国西雅图，第533–549页。计算语言学协会。

何明山、阿迪提·库马雷桑与李罗维。2024年。跨模态融合：基于少量上下文无关学习提升跨模态仇恨言论检测。收录于《2024自然语言处理实证方法会议论文集》第7785–7799页，美国佛罗里达州迈阿密市，计算语言学协会。

爱德华·J·胡、沈业龙、菲利普·沃利斯、艾伦·朱泽远、李元志、王世安、王璐和陈伟珠。2022年。LoRA：大型语言模型的低秩自适应。国际学习表征会议论文集。

胡宇、奥蒂莉亚·斯特雷特库、卢春涛、克里希纳穆尔蒂·维斯瓦纳坦、畑健二、罗恩明、兰杰·克里希纳与阿里尔·福克斯曼。2024年。视觉程序蒸馏：将工具与程序化推理提炼为视觉语言模型。载于《2024年IEEE/CVF计算机视觉与模式识别会议 (CVPR) 论文集》，第9590–9601页，美国华盛顿州西雅图市。IEEE。

黄建钊、林宏展、刘子岩、罗子阳、陈光、马静。2024年。基于Imm代理的低资源有害模因检测方法。收录于《2024自然语言处理经验方法会议论文集》第2269–2293页，美国佛罗里达州迈阿密市，计算语言学协会出版。

季俊辉、林宣睿与乌斯曼·纳西姆。2024年。《Ca-align：通过信息性描述提升跨模态对齐以检测有害表情包》。收录于《2024年ACM网络会议论文集》第4585–4594页，新加坡，ACM。

杰夫·约翰逊、马蒂斯·杜泽与埃尔韦·热古。2021年。基于GPU的十亿级相似性搜索。《IEEE大数据汇刊》第7卷第3期：535–547页。

杜韦·基拉、哈迈德·菲鲁兹、阿拉文德·莫汉、维达努吉·戈斯瓦米、阿曼普里特·辛格、普拉提克·林吉亚和达维德·泰斯特吉内。2021年。《仇恨表情包大作战：多模态表情包中的仇恨言论检测》。
(arXiv:2005.04790). ArXiv:2005.04790 [cs].

Gokul Karthik Kumar和Karthik Nandakumar。2022年。
仇恨剪辑器 (Hate-CLIPper)：基于CLIP特征跨模态交互的多模态仇恨梗分类方法。载于第二届跨模态信息处理研讨会论文集。

- 《积极影响自然语言处理 (NLP4PI)》第171-183页,阿拉伯联合酋长国阿布扎比(混合型)。计算语言学协会。
- 李秀军、尹xi、李春元、张鹏川、胡晓伟、张磊、王丽娟、胡厚东、李东、韦福如、崔业进和高建锋。
2020年。《奥斯卡:面向视觉-语言任务的对象语义对齐预训练》,收录于《计算机科学讲义》第12375卷,第121-137页。施普林格国际出版集团,瑞士沙姆。
- 林宏展、罗子阳、高伟、马静、王波与杨瑞超。
2024年。通过大型语言模型间的多模态辩论实现可解释有害模因检测。收录于《ACM网络会议2024论文集》(WWW '24),第2359-2370页,美国纽约。计算机协会。
- 菲利普·利普、尼辛·霍拉、山塔努·钱德拉、桑托什·拉贾马尼卡姆、乔治奥斯·安托尼乌、叶卡捷琳娜·舒托娃和海伦·亚纳库达基斯。2020年。一种多模态框架用于检测仇恨memes。(arXiv:2012.12871)。ArXiv:2012.12871 [cs]。
- 刘晨、格雷戈尔·盖格尔、罗宾·克雷布斯与伊琳娜·古列维奇。2022年。《图解语义:政治观点模因中隐喻语言识别数据集》。收录于《2022自然语言处理实证方法会议论文集》,阿联酋阿布扎比,第7069-7086页。计算语言学协会。
- 刘海天、李春元、李玉恒与李永幸。2023a.基于视觉指导调优的改进基准模型。(arXiv:2310.03744)。ArXiv:2310.03744 [cs]。
- 刘海天、李春元、吴庆阳和李永幸。2023b.视觉教学tuning。(arXiv:2304.08485)。ArXiv:2304.08485 [cs]。
- 梅景彪、陈景红、林伟哲、比尔·伯恩与马库斯·托马林。2024年。基于检索引导的对比学习提升仇恨表情包检测效果。收录于《计算语言学协会第62届年会论文集》(第一卷:长篇文章),泰国曼谷,第5333-5347页。计算语言学协会。
- 尼古拉斯·穆尼霍夫。2020年。Vilio:最先进的视觉语言模型应用于仇恨memes。(arXiv:2012.07788)。ArXiv:2012.07788 [cs]。
- 瓦伊里穆·恩德里图。2020年。联合国关于仇恨言论的战略和行动计划。
- Khoi P.阮南与吴文森(2024).计算模因理解:综述.收录于《2024年自然语言处理经验方法会议论文集》第21251-21267页,美国佛罗里达州迈阿密市,计算语言学协会出版。
- OpenAI. 2023.Gpt-4技术报告。
(arXiv:2303.08774). ArXiv:2303.08774 [cs].
- OpenAI. 2024a. Gpt-4o系统卡。
(arXiv:2410.21276). ArXiv:2410.21276 [cs].
- OpenAI. 2024b. OpenAI o1系统卡。
(arXiv:2412.16720). ArXiv:2412.16720 [cs].
- 尼尔马伦杜·普拉卡什、何明山与李凯伟。2023年。《Totaldefmeme:新加坡全面防御主题多属性模因数据集》。收录于《第十四届ACM多媒体系统会议论文集》(MMSys '23),美国纽约,第369-375页。美国计算机协会。
- 沙拉曼·普拉马尼克、迪米塔尔·迪米特洛夫、里图帕娜·穆克吉、希瓦姆·夏尔马、M·D·沙德·阿赫塔尔、普雷斯拉夫·纳科夫和坦莫伊·查克拉博蒂。
2021a.识别有害网络梗及其目标。载于《计算语言学协会研究成果:ACL-IJCNLP 2021》,第2783-2796页,在线出版。计算语言学协会。
- 什拉曼·普拉马尼克、希瓦姆·夏尔马、迪米塔尔·迪米特洛夫、M·D·沙德·阿克塔尔、普雷斯拉夫·纳科夫和坦莫伊·查克拉博蒂。2021b. Momenta:检测有害模因及其目标的多模态框架。收录于《计算语言学协会研究成果集:EMNLP 2021》,第4439-4455页,多米尼加共和国蓬塔卡纳。计算语言学协会。
- 亚历克·拉德福德、金钟旭、克里斯·哈利西、阿迪提亚·拉梅什、加布里埃尔·高、桑德希妮·阿加瓦尔、吉里什·萨斯特里、阿曼达·阿斯科尔、帕梅拉·米什金、杰克·克拉克、格雷琴·克鲁格和伊利亚·苏茨克弗。2021年。《通过自然语言监督学习可迁移视觉模型》。载于第38届国际机器学习会议论文集,第8748-8763页。PMLR。
- 邵青仁、何凯明、罗斯·吉尔希克和孙健。2015年。《更快的r-cnn:基于区域建议网络的实时目标检测》。收录于《神经信息处理系统进展》第28卷,柯伦联合公司出版。
- 弗洛里安·施罗夫、德米特里·卡连尼琴科与詹姆斯·菲尔宾。2015年。Facenet:面向人脸识别与聚类的统一嵌入方法。收录于《2015年IEEE计算机视觉与模式识别会议(CVPR)论文集》第815-823页。ArXiv:1503.03832 [cs]。
- 西德汉特·比克拉姆·沙阿、舒瓦姆·希瓦科蒂、马希普·乔杜里和王浩涵。2024年。模因片段:基于片段表征的多模态模因分类方法。收录于《2024自然语言处理经验方法会议论文集》第17320-17332页,美国佛罗里达州迈阿密市,计算语言学协会出版。
- 沙杜尔·苏里万希、巴拉蒂·拉贾·查克拉瓦蒂、米哈埃尔·阿尔坎与保罗·布伊特拉尔。2020年。多模态模因数据集(multioff)用于识别图像与文本中的冒犯性内容。载于第二届会议论文集。

关于网络钓鱼、攻击和网络欺凌的研讨会，第32-41页，法国马赛。欧洲语言资源协会（ELRA）。

王鹏、白帅、谭思南、王世杰、范志浩、白进泽、陈克勤、刘雪静、王嘉林、葛文彬、杨帆、唐凯、杜梦飞、任旋城、门瑞、刘大恒、周昌、周敬仁、林俊阳。2024年。Qwen2-vl：提升视觉语言模型在任意分辨率下的世界感知能力。（arXiv：2409.12191）
ArXiv:2409.12191 [cs].

约翰·伍德豪斯。2022年。监管网络危害。英国议会。

张鹏川、李秀军、胡晓伟、杨建伟、张磊、王丽娟、崔业进、高建锋。2021. Vinvl：视觉语言模型中的视觉表征重构。第5579-5588页。

罗俊. 2020.增强多模态变换器的外部标签与领域预训练：仇恨梗挑战赛获胜方案.（arXiv：2012.08290）.
ArXiv:2012.08290 [cs].

永硕宗、翁德雷·博赫达尔与蒂莫西·霍斯佩达莱斯。2024年。VI-icl基准测试：多模态情境学习基准测试中的魔鬼细节。arXiv预印本arXiv：2403.13164。

数据集详细信息和统计信息

表5显示了我们的评估数据集的数据分割。

仇恨表情包（基拉等人，2021）由Meta于2020年发布，该数据集包含12,000个经过专家标注为仇恨或无害的表情包。这个基准数据集综合了针对宗教、种族、残障和性别的表情包。它包括混杂因素的例子，其中良性的模因是通过改变图像或文本来挑战模型在多模态推理方面的能力。

HarMeme与Harm-P数据集：HarMeme是一个包含约3000个以COVID-19相关政治梗图为核心的语料库。其姊妹数据集Harm-P（普拉曼尼克等人，2021b）则收录了约3000个涉及美国政治的梗图。尽管原版HarMeme在后续研究中被更名为Harm-C，但为保持学术传承，我们沿用其原始名称（曹等人，2022）。该数据集将梗图划分为三类：极具危害性、部分危害性和无害性。与先前研究（曹等人，2022；普拉曼尼克等人，2021b）一致，我们将极具危害性的内容进行合并处理。

将有害和部分有害的类别归为一个可恨的类别，而将无害的模因视为良性的。

MAMI数据集（费尔西尼等人，2022）专注于从推特、红迪等各类社交媒体平台，以及表情包创作分享网站，甚至反女性网站和论坛中检测厌女梗。该数据集包含两项任务的标注：(1) 二元分类与(2) 厌女症类型划分。本研究致力于解决如何判断一个网络梗是否具有厌女属性这一二元问题。

MultiOFF（苏里万希等人，2020）该数据集由Reddit、Facebook、Twitter和Instagram平台收集的网络梗图组成，专门用于检测冒犯性内容。值得注意的是，其训练集规模极其有限，仅包含不到500个梗图样本。我们利用该数据集来评估本方法在超低资源条件下的适用性。

PrideMM（Shah等人，2024）包含LGBTQ+主题的标注表情包，用于四个任务：仇恨言论检测、仇恨目标识别、主题立场分类和幽默检测。在本研究中，我们使用仇恨言论分类的标注数据进行恶意表情包检测。

数据集	列车		试验	
	#良性仇恨	#良性仇恨		
HatefulMemes	5450	3050	500	500
哈米	1949	1064	230	124
妈妈	4500	4500	500	500
哈姆-P	1534	1486	173	182
多边形关闭	258	187	58	91
骄傲MM	2581	2482	260	247

表5：HatefulMemes和HarMeme数据集的统计汇总

要访问Facebook的HatefulMemes数据集，必须遵循Facebook²的许可。
HarMeme和Harm-P仅用于研究目的，未获得商业使用许可。MultiOFF采用CC-BY-NC协议授权。MAMI采用Apache许可证2.0。PrideMM没有指定的许可证。

²<https://hatefulmemeschallenge.com/#download>

B实验设置和实施细则

环境。PyTorch 2.5.1, CUDA 12.4实验采用Huggingface Transformer 4.45.0和Python 3.10.12进行开发。密集检索使用FAISS (Johnson等人, 2021) 向量相似度搜索库 (版本faiss-gpu 1.7.2)。所有实验指标均通过TorchMetrics 1.0.1进行计算。

具体实施细节。我们采用QLoRA (Dettmers等人, 2023) 对所有LMM模型进行微调, 实验表明LoRA和QLoRA在此任务上的表现相当, 且显著优于全参数微调。微调的具体方法详见附录B.1。所有报告的指标均基于五次不同随机种子运行的平均值。在统计学显著性检验中, 每个模型均采用不同随机种子进行五次独立运行。对于基线模型, 我们严格遵循其原始论文中规定的设置参数。

实验环境说明。本研究在配备英伟达 RTX 3090显卡的工作站上开展实验, 其中完整的参数微调实验是在4块A100-80GB-SXM系列GPU上完成的。

运行时间在HatefulMemes数据集上, LMM-RGCL两阶段微调的运行时间大约是4小时, 在单个RTX 3090上, 这与SFT相当。

为了优化第二阶段的效率, 我们预先从冻结的LMM中提取最终的隐藏状态, 并在训练前将其存储到磁盘上, 避免重复的LMM计算。这将第二阶段的训练时间减少到大约10分钟。

在本次消融实验中, 我们重点研究将两阶段损失函数整合为单次微调阶段对模型性能的影响。由于LMM在此设置下仍保持可训练状态, 我们无法预先计算并存储冻结的LMM特征, 这导致计算成本显著增加。在单块RTX 3090显卡上完成微调过程, 该方法大约需要12小时。

对于全参数微调, 在4 A100-80G上训练需要6小时。

B.1 LLaVA和Qwen2VL实验

我们遵循标准的LMM微调方法, 在整个微调过程中冻结视觉模块

格式规范。为确保格式及时性, 我们采用InstructBLIP框架 (戴等人, 2023)。针对LLaVA小样本实验, 由于该模型未专门训练情境学习能力, 我们参照宗等人提出的实验流程进行操作。(2024) 为在LLaVA上实现少样本学习。针对LLaVA (Liu等人, 2023b, a) 的微调工作, 我们沿用原始超参数设置³, 分别在下游任务的SFT和LMM-RGCL第一阶段微调中进行优化。

对于Qwen2VL的微调, 我们采用了在SFT和LMM-RGCL第一阶段微调中, 官方推荐使用LLaMA-Factory 0.9.1⁴ 库进行微调, 并采用官方超参数设置以适应下游任务需求。针对Qwen2VL的少样本学习场景, 我们遵循官方多轮对话提示格式, 确保与模型预期应用场景保持一致。

B.2 MLP和第二阶段微调的超参数

MLP和第二阶段RGCL微调的默认超参数如表6所示。建模超参数基于RGCL的设置 (Mei等人, 2024)。采用该超参数配置后, 可训练参数数量约为500万。

超参数建模	价值
MLP投影维度	1024
MLP中的层数	2
优化	亚当·W
最大次数	30
批量大	64
学习	0.0001
权重衰	0.0001
梯度剪切值	0.1
RGCL hyperparameter	价值
#需要硬核的负面案例	1
伪黄金正例	1
相似性度量	余弦相似
损失函	国家法律图书馆
RKC的顶级配置	20

表6：默认超参数值

C基线方法

- 视觉编程蒸馏 (VPD) (胡等人, 2024年) 通过微调模型的能力构建了一个智能学习模型框架。

³<https://github.com/haotian-liu/LLaVA> ⁴<https://github.com/hiyouga/LLaMA-Factory>

通过使用外部工具（例如编写和运行程序）来优化PaLI-X 55B模型。VPD对模型进行微调后，在HatefulMemes数据集上取得了业界领先的性能表现。

- ISSUES (Burbi等人, 2023) 采用文本反转技术结合多层投影和特征组合器来增强预训练的CLIP编码器，在HarMeme数据集上取得了业界领先的结果。
- RGCL (Mei等人, 2024) 通过将对比学习目标应用于预训练的CLIP编码器，学习具有仇恨感知能力的视觉和语言表征，在MultiOFF数据集上取得了最先进的性能。
- ExplainHM (Lin等人, 2024) 对三个大型语言模型 (LLM) 进行微调，将它们配置为两名辩手（争论某个模因是否具有仇恨属性）和一名法官（总结辩手观点），用于解释和分类具有仇恨属性的模因。
- Pro-Cap (曹等人, 2023) 采用提示技术指导预训练视觉语言模型生成反映仇恨内容的图像描述。这些生成的描述随后与文本信息结合，以提升仇恨梗检测效果。
- MemeCLIP (Shah等人, 2024) 利用CLIP特征和特征适配器来缓解过拟合，并采用余弦分类器来解决类别不平衡问题。
- MOMENTA (普拉曼尼克等人, 2021b) 利用可训练的融合层——例如跨模态注意力融合——整合CLIP提取的多模态特征，以提高仇恨表情包检测效果。
- HateCLIPper (Kumar 和 Nandakumar, 2022) 探索了多种策略来对齐和融合基于CLIP的编码器中的视觉和文本模态，从而增强其在具有挑战性的仇恨表情包案例中的性能。
- LOREHM (黄等人, 2024) 采用基于智能体的LMM框架，利用少量上下文学习和自我改进能力进行低资源仇恨表情包检测。
- Mod-Hate (曹等人, 2024) 通过训练LoRA模块套件，并利用少量示例数据来构建模块组合器。

为LoRA模块分配权重，以有效检测低资源的仇恨模因。

D在不同的微调方案下比较RKC和In-Context学习

在本节中，我们对比了预训练语言模型、SFT语言模型以及采用LMM-RGCL框架微调的语言模型，在跨数据集场景下RKC推理模式与少量样本上下文学习的性能表现。如表7所示，RKC在所有语言模型变体中均持续优于少量样本上下文学习方法，这表明RKC能更有效地利用示范样本。此外，采用RKC微调的LMM-RGCL语言模型表现优于SFT语言模型，突显了我们微调策略的优势。

模型	模式	仇恨表情包		哈密	
		AUC	Acc.	AUC	Acc.
预训练	少发71.5		63.8	71.5	67.2
预训练	美国	74.5	64.5	80.1	72.4
软件与技术	少发子弹	72.3	60.6	67.2	62.4
软件与技术	美国	75.8	67.1	84.5	75.4
LMM-RGCL	少发子弹	70.8	63.5	73.2	68.1
LMM-RGCL	美国	77.1	69.3	88.8	81.7

表7：在跨数据集场景下，对比预训练模型、SFT与LMMRGCL系统在少样本学习中的表现，并将RKC与Qwen2VL-7B进行对比。详见表2

A损失函数消融研究

表8展示了从微调的不同阶段移除各损失目标后的结果。值得注意的是，当在第一阶段移除逻辑回归组件的交叉熵损失时，LRC通过反向传播无法正常训练，导致性能等同于随机猜测。因此，我们排除了这种情况。总体而言，我们观察到从微调目标中移除任何损失函数都会导致性能显著下降，这突显了每个损失项在优化模型中的重要性。

F案例分析

F.1 比较SFT和LMM-RGCL预测

表9给出了我们的LMM-RGCL方法成功纠正预测错误的示例

模式	HatefulMemes		哈米	
	AUC	Acc.	AUC	Acc.
LMM-RGCL	91.1	82.1	93.2	88.1
无 L^{LM} 在阶段1无	88.4	79.6	90.9	85.1
L^{RGCLL} 在阶段2无 L^{LR}	90.2	81.2	91.9	86.4
在阶段2	89.2	80.6	91.6	87.2

(a) 监督设置，见表1

模式	仇恨表情包		哈米	
	AUC	Acc.	AUC	Acc.
LMM-RGCL	77.1	69.3	88.8	81.7
第1阶段无 L^{LM}	75.4	66.6	87.3	81.1
第2阶段无 L^{RGCLL}	73.8	64.3	82.9	76.5
第2阶段无 L^{LR}	76.4	67.9	86.9	80.6

(b) 跨数据集设置，见表2

表8：LMM-RGCL两阶段微调框架在Qwen2VL-7B上的消融研究，评估删除任何损失目标的影响。

这些案例由SFT模型在Qwen2VL-7B上生成。案例1-4涉及恶意表情包，而案例5-6则是SFT模型误判的良性表情包，主要原因是多模态对齐效果不佳。这类案例需要深度理解图像与文本的关联性，这正是我们提出的LMMRGCL方法有效解决的难题。例如在案例2中，模型需要运用其对日本文化的认知，并将这种文化理解与图像中的视觉线索相结合。

F.2 误差分析

在表10中，我们展示了LMMRGCL无法纠正基线SFT模型所犯错误的示例。在第一个案例中，该模型难以理解游泳者身体残疾所需的细致视觉信息。此外，这些案例需要复杂的推理能力来评估模因的仇恨属性。当前模型在解读这种微妙含义方面仍面临挑战。不过我们预计，像 OpenAI-o1 (OpenAI, 2024b) 和 DeepSeek-R1 (DeepSeek-AI, 2025) 这类新兴系统所具备的高级推理能力，将有助于克服这些局限性。

G AI助手

我们的编码工作得到了Github Copilot的协助。OpenAI的ChatGPT仅用于校对和拼写检查。我们声明本文所呈现的内容完全原创。

	案例1	案例2	案例3
表情包			
真实	#仇恨	#仇恨	#仇恨
软件与技术	#良性	#良性	#良性
LMM-RGCL	#仇恨	#仇恨	#仇恨
	案例4	案例5	案例6
表情包			
真实	#仇恨	#良性	#良性
软件与技术	#良性	#仇恨	#仇恨
LMM-RGCL	#仇恨	#良性	#良性

表9：SFT Qwen2VL-7B与LMM-RGCL Qwen2VL-7B模型在仇恨表情包数据集上的案例可视化。案例5的梗图中出现昆虫元素，我们通过模糊滤镜处理使其不可见。

	案例1	案例2	案例3
表情包			
真实	#仇恨	#仇恨	#仇恨
软件与技术	#良性	#良性	#良性
LMM-RGCL	#良性	#良性	#良性

表10：SFT Qwen2VL-7B和LMM-RGCL Qwen2VL-7B模型在HatefulMemes数据集上的错误案例